

Tietorakenteet ja algoritmit -harjoitustyö testausdokumentti

Hannes Ihalainen

February 23, 2018

Contents

1	Toteutetut tietorakenteet ja niiden toimivuuden testaus	3
2	Nopeuden testaaminen	3
2.1	Syötteen pituus	4
2.2	Aakkoston koko	5
3	Longest Common Substring	6

1 Toteutetut tietorakenteet ja niiden toimivuuden testaus

Projektissa toteutettiin seuraavat tietorakenneluokat

Vector

FastSet

UkkonenTree - Edget Vectorissa

UkkonenTree - Edget Vectorissa järjestystä ylläpitäen

UkkonenTree - Edget $O(m)$ -kokoisessa taulukossa

UkkonenTree - Edget FastSetissä

UkkonenTree - Edget std::setissä (vertailua varten)

Luokkia on yksikkötestattu. Lisäksi Ukkosen algoritmin toimivuutta on tutkittu satunnaisilla syötteillä substring-kyselyillä.

Yksikkötestit ovat test/ -kansiossa.

Satunnaistestaus on kansiossa bin/substring. Python2-skripti tester.py ajaa satunnaistestejä silmukassa. Skriptiä gener.py käytetään testien generoimiseen.

Satunnaistestit generoidaan generoimalla ensin satunnainen merkkijono. Sen jälkeen generoidaan joukko toisia merkkijonoja valitsemalla alkuperäisestä merkkijonosta satunnainen substring ja vaihtamalla siitä 0-3 merkkiä. Tämän jälkeen testataan jokaisella ohjelmalla, vastaako se oikein kyselyyn, mitkä merkkijonot ovat alkuperäisen merkkijonon substringejä. Vastaus vahvistetaan vertailemalla tulostetta std::substring -funktiota käyttävän ohjelman tulosteeseen.

2 Nopeuden testaaminen


Vertasin eri toteutuksia toisiinsa mittaamalla time-komennolla aikaa satunnaisesti generoidun merkkijonon suffiksipuun muodostamiseen. Kansiossa bin/speedtest on python-skriptit, jolla mittasin suoritusajat.

Taulukko aikavaatimuksista.

	Vect.	Vect.järj.	Taulukko	FastSet	stdset
Edgen haku	$O(m)$	$O(\log m)$	$O(1)$	$O(\log^2 m)$	$O(\log m)$
Edgen lisäys	$O(m)$	$O(m)$	$O(1)$	$O(\log m)$	$O(\log m)$
Noden lisäys	$O(1)$	$O(1)$	$O(m)$	$O(1)$	$O(1)$
Kok.aikavaatimus	$O(n * m)$	$O(n * m)$	$O(n * m)$	$O(n \log^2 m)$	$O(n \log m)$
Muistinkäyttö	$O(n)$	$O(n)$	$O(n * m)$	$O(n)$	$O(n)$

2.1 Syötteen pituus

Kaaviossa mitatut ajat eri ohjelmilta, kun syötteen pituutta muutetaan. Aakkoston koko oli kaikissa testeissä 128. Kuvaan on otettu eri pituisilta satunnaisilta syöteiltä viiden kerran keskiarvo. Testit on suoritettu satunnaisessa järjestyksessä, jolloin mahdollinen koneen suoritusnopeuden vaihtelun vaikutus tasoittuu.



Punainen viiva: Vector

Sininen viiva: FastSet

Syaani viiva: Vector järjestystä ylläpitäen


Violetti viiva: Taulukko

Vihreä viiva: std::set

Violetti viiva (Taulukko-implemantaatio) muuttaa suuntansa jyrkästi ylöspäin noin kohdassa 4000000, koska tietokoneen RAM-muisti loppuu sen jälkeen kesken.

2.2 Aakkoston koko

Kaaviossa mitatut ajat, kun syötteen koko on 2000000, aakkoston kokoa muutetaan. X-akselilla on logaritminen skaalaus. Aakkoston kokona on testattu tässä eri 2:n potensseja. Kuvaan on otettu joka koolta viiden kerran keskiarvo. Testit on suoritettu satunnaisessa järjestyksessä, jolloin koneen suoritusnopeuden vaihtelun vaikutus tasoittuu.



Punainen viiva: Vector

Sininen viiva: FastSet

Syaani viiva: Vector järjestystä ylläpitäen

Violetti viiva: Taulukko

Vihreä viiva: std::set

Violetti viiva (Taulukko) loppuu kesken, koska suuremmalla aakkoston koolla muistinkäyttö kasvaa liian isoksi.

Tulosten perusteella pienellä aakkostolla ($m < 20$) Taulukko-ratkaisu on nopein. Aakkoston koon ollessa n. välillä $20 < m < 200$ järjestemätön vektori on nopein. Aakkoston koon kasvaessa muutamasta sadasta muutamaan tuhanteen järjestetty vektori on nopein. Siitä eteenpäin FastSet ja std::set ovat selvästi nopeampia kuin muut. std::set ohittaa FastSetin nopeudessa vasta kohtuullisen myöhään

Kuvassa näkyy, miten järjestettyä vectoria, FastSettiä ja std:n settiä käyttävät

implementaatiot toimivat nopeammin, kun aakkoston koko kasvaa muutamasta tuhannesta muutamaan kymmeneen tuhanteen. Tämä johtune siitä, että kun aakkoston koko on suuri suhteessa merkkijonon kokoon, puusta tulee matala ja leveä, ja edgejen pituudet (lehtiin meneviä edgejä tietysti lukuunottamatta) ovat lyhyitä. Tällöin tarvittavien edgejen splittausten määrä vähenee ja suurempi osa tiloista on jonkin noden kohdalla, jolloin siirtymien olemasolon tutkiminen on nopeampaa.

3 Longest Common Substring